

BERT を用いた原文と要約文の 分散表現の統合手法

創発ソフトウェア研究室 (第 1 グループ)

2210104043 高山 裕成

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の展望

発表の流れ

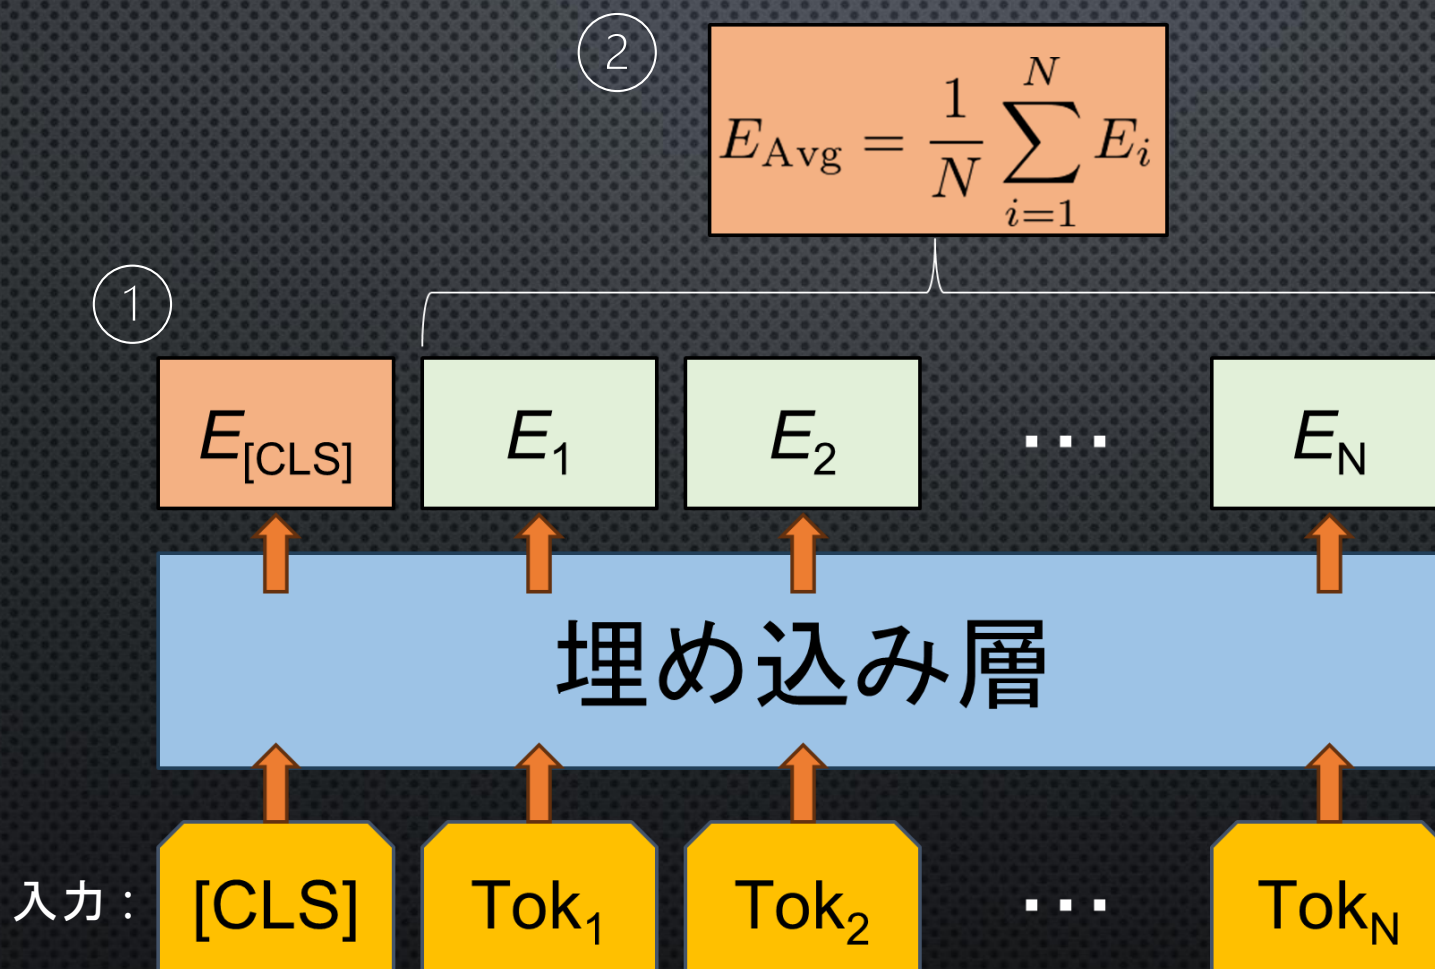
- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の展望

大規模言語モデル (Large Language Model, LLM) の進化

Transformer 構造を持つ BERT や
GPT (Generative Pre-trained Transformer) など
LLM の利用需要が拡大

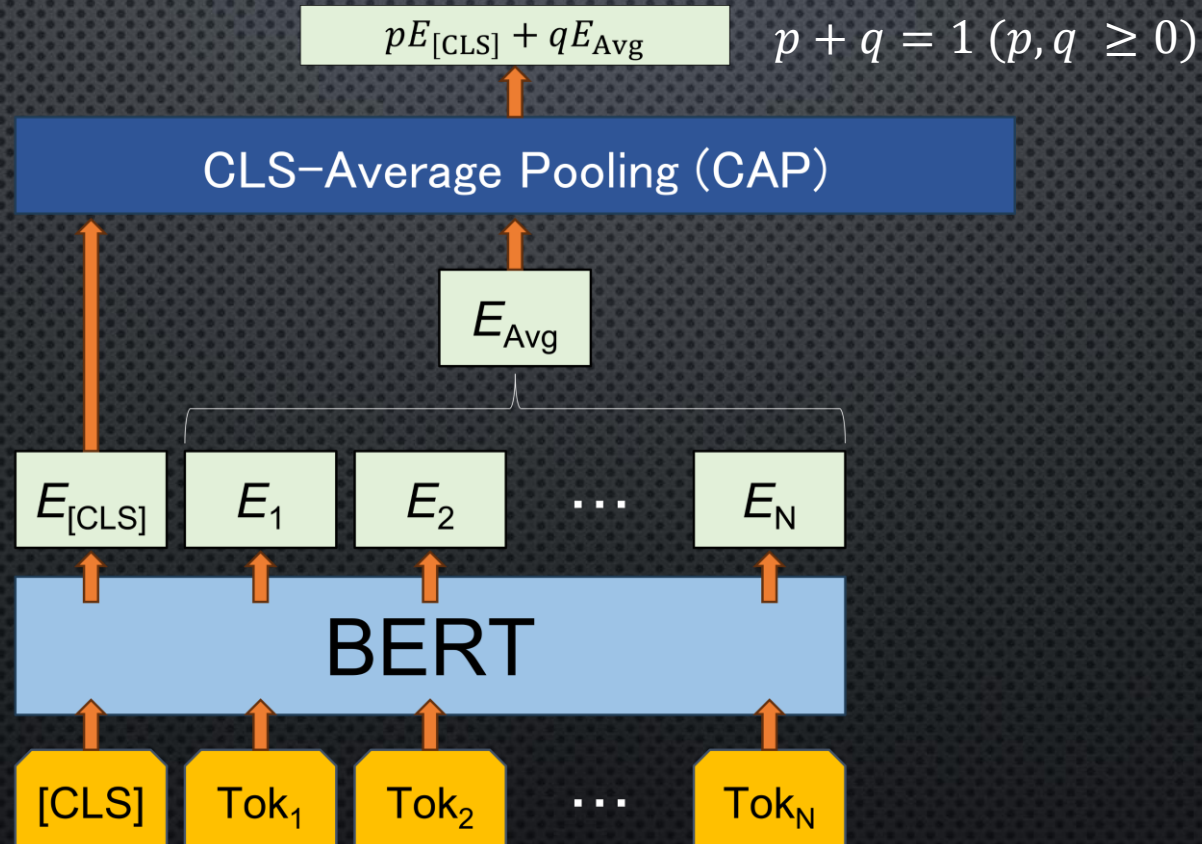
⇒ より高性能なモデルの構築のためには
文章全体の適切な分散表現を獲得し
最適な処理の選択が重要

自然言語処理における分散表現のプーリング例



先行研究

CLS-Average Pooling (CAP) 層の導入 [大和, 2024]



大和秀徳. BERT の分散表現に対する学習可能な重みを持つプーリング手法の提案, 大阪公立大学大学院情報学研究科 基幹情報学専攻 知能情報分野 修士論文, 2024

本研究の概要

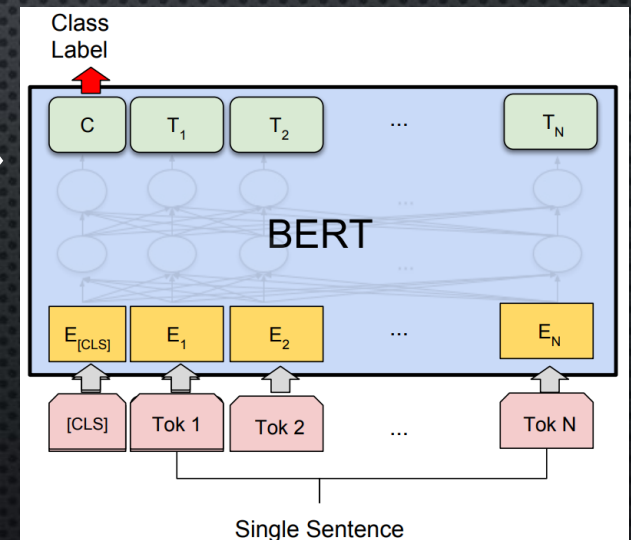
- ① LLM API を用いた要約文生成
- ② CAP をベースとした要約文情報を組み込んだプーリング手法の提案
- ③ テキスト分類タスクによる提案手法に対する有効性の検証

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の展望

BERT^[1] (Bidirectional Encoder Representations from Transformers)

- 複数の双方向 Transformer に基づく汎用言語モデル
- 事前学習済みモデルを他のタスクに転移させることが容易
- 東北大学による事前学習済みモデル BERT-base^[2] を使用



[1] Devlin, Jacob and Chang, Ming-Wei and Lee, Kenton and Toutanova, Kristina.
BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. 2019.

[2] <https://huggingface.co/cl-tohoku/bert-base-japanese-v3>

PLaMo

- Preferred Elements 社が開発・公開している日本語に特化した大規模言語モデル
- 既存モデルをベースに用いず合計 2 兆トークン分のテキストデータで事前学習 (PLaMo-100B モデル)
- 要約文生成には 'plamo-beta' モデルを使用

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の展望

livedoor ニュースコーパスデータセット

- 9つのカテゴリ, 計 7,367 記事
- 各記事データ D はカテゴリ名 D_{label} , 記事タイトル D_{title} , 記事本文 D_{body} などのメタデータから構成
- 本研究では以下のようにラベルとカテゴリ名を対応

0 : 独女通信	5 : Peachy
1 : IT ライフハック	6 : エスマックス
2 : 家電チャンネル	7 : Sports Watch
3 : livedoor HOMME	8 : トピックニュース
4 : MOVIE ENTER	

要約文 D_{summary} の生成手法 (PLaMo API を使用)

1. 各記事データ D に含まれる, D_{title} および D_{body} から
プロンプトを作成
2. PLaMo API からの回答を要約文 D_{summary} とする

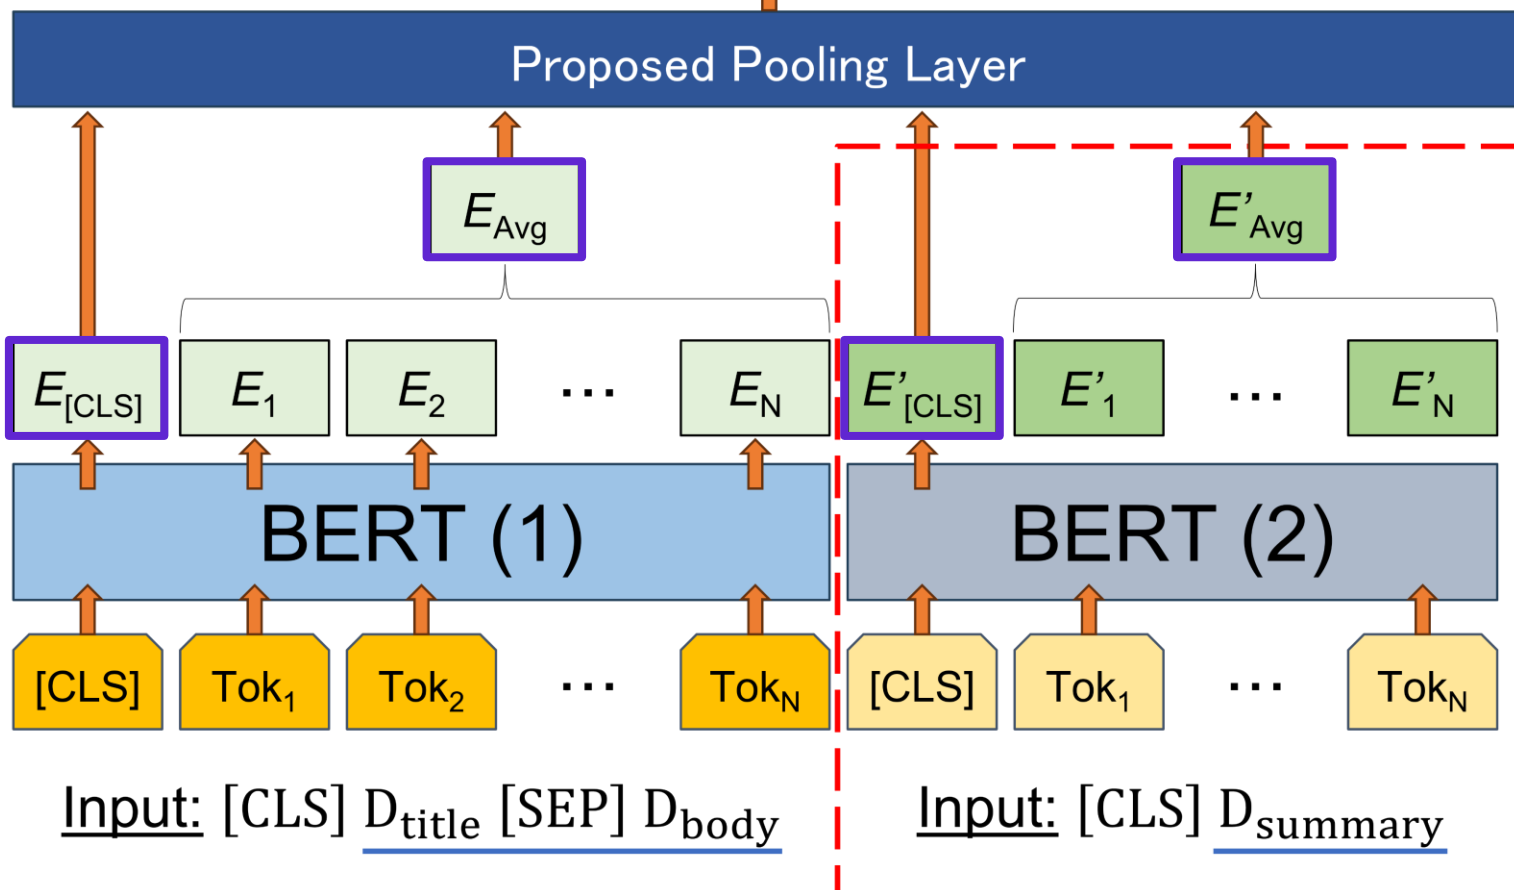
$$\left\{ \begin{array}{l} D_{\text{summary}} = \mathcal{L}(D_{\text{prompt}}) \quad \mathcal{L} : \text{大規模言語モデル API (e.g., ChatGPT API, PLaMo API)} \\ D_{\text{prompt}} = \left[\begin{array}{l} \text{"role" : "system", "content" : "あなたは優秀な AI アシスタントです。"} \\ \text{"role" : "user", "content" : "以下は「 D_{title} 」というタイトルの"} \\ \text{記事の本文です。内容を要約し、} \\ \text{結果のみを出力してください。"} \\ \text{"role" : "user", "content" : " D_{body} "} \end{array} \right] \end{array} \right.$$

提案手法 1

BERT の並列化による要約文情報の統合手法モデル

$$C = pE_{[\text{CLS}]} + qE_{\text{Avg}} + rE'_{[\text{CLS}]} + sE'_{\text{Avg}}$$

$$p + q + r + s = 1 \quad (p, q, r, s \geq 0)$$



提案手法 1

学習可能パラメータ p, q, r, s の更新式

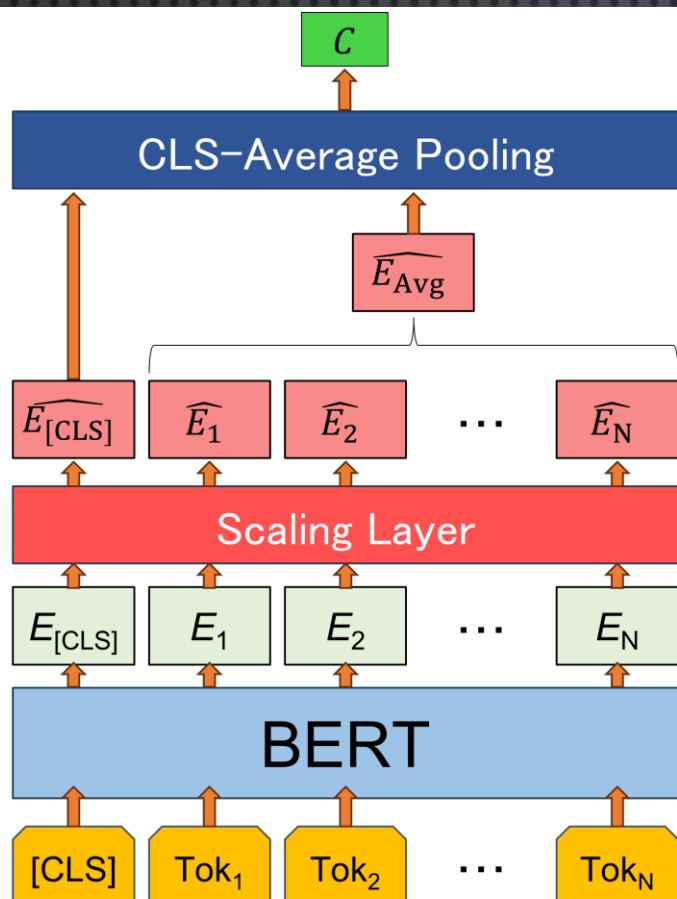
更新後のパラメータを p', q', r', s' とすると

$$p' = \frac{p^2}{p^2 + q^2 + r^2 + s^2}, q' = \frac{q^2}{p^2 + q^2 + r^2 + s^2}$$

$$r' = \frac{r^2}{p^2 + q^2 + r^2 + s^2}, s' = \frac{s^2}{p^2 + q^2 + r^2 + s^2}$$

提案手法 2

スケーリング層を導入した要約文情報の統合手法モデル



$$\hat{E}_i = \boxed{score(Tok_i)} \times E_i$$

- Tok_i が **[CLS]** または **[SEP]**
 $score(Tok_i) = 1$
- Tok_i がストップワードの場合
 $score(Tok_i) = -\alpha \ (\alpha \geq 0)$
- Tok_i がストップワードではない場合
 $score(Tok_i) = \alpha \times tfidf(Tok_i, D_{summary}) + 1$

ストップワード辞書は
spaCy, slothLib のもの, 句読点や
記号, **[PAD]**

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の展望

実験設定

- 9 クラスのテキスト分類タスク (記事ラベル推定)
- 訓練データ : 検証データ : テストデータ = 8 : 1 : 1 に分割
- 検証データにおける F1 値 が最も高い epoch におけるモデルで評価する, ランダムシードで 3回試行
- 分類器は 1 層の全結合層, BERT は最終層のみ fine tuning

label	0	1	2	3	4	5	6	7	8	合計
訓練	684	695	690	421	700	645	713	716	631	5,895
検証	88	80	88	42	93	100	77	105	63	736
テスト	98	95	86	48	77	97	80	79	76	736

実験パラメータ

学習パラメータ	値
エポック数	20
バッチサイズ	16
最適化手法	Adam
学習率	3.0×10^{-5}
損失関数	Cross Entropy Loss
分類器	全結合層

重みパラメータの初期値はパラメータ数を
N とすると $1/N \Rightarrow$ 後で書く

実験結果：



	評価	
	Acc	F1 値 (weighted)
提案手法 1	0.9655 (0.0017)	0.9652 (0.0017)
提案手法 2 ($\alpha = 1$)	0.9587 (0.0061)	0.9584 (0.0062)
提案手法 2 ($\alpha = 5$)	0.9633 (0.0019)	0.9630 (0.0021)
従来手法 (CAP)	0.9583 (0.0026)	0.9580 (0.0026)

考察

提案手法 1 : 学習曲線 (重みパラメータ)

(図が見づらいので要変更)

① 提案手法 1(パラメータ p, q, r, s の推移) ② 従来手法 (パラメータ p, q の推移)



学習後のパラメータの値:

$$(p, q, r, s) = (0.398, 0.217, 0.245, 0.140)$$


$$(p, q) = (0.607, 0.393)$$

考察

提案手法 1 : トークン数による学習への影響

訓練用データのトークン数分布

	トークン数	
	< 512	≥ 512
原文	2148	3747
要約文	5884	11




- => ・ 欠損した原文データの重要な文脈情報の補完
・ 原文データの重要な文脈情報の強調

考察


提案手法 2: 学習曲線 (重みパラメータ)

① 提案手法 2(パラメータ p, q の推移 $\alpha=5$) ② 従来手法 (パラメータ p, q の推移)



学習後のパラメータの値:

$$(p, q) = (0.362, 0.638)$$



$$(p, q) = (0.607, 0.393)$$

考察

提案手法2 ($\alpha=5$) 推論時のアテンションの変化

従来手法 (CAP)

[CLS]無料で使えるデジタルフィルターや便利なスタンプ機能搭載!小##技の効##いたカメラアプリ「LINEc##ame##ra」【Androidアプリ】[SEP]画像加工編集が楽しいカメラアプリSNSやブログの更新をスマートフォンで行っている人も多くなっているようです。スマートフォンは、写真を撮って共有する方法がフィーチャーフォンより柔軟で使いやすいことや、自分の好きなカメラアプリや画像編集アプリを選##べる点も魅力の一つ。今回紹介するAndroid向けアプリ「LINEc##ame##ra」は撮##る・編集する・デコ##るなど簡単操作で個性的な写真を作って共有できるカメラアプリです。LINEc##ame##raはどんなアプリLINEc##ame##raは、カメラ機能を使って撮影もしくは端末内の画像を加工・編集できるカメラアプリです。通常の4:3の画面比率での撮影以外に、1:1の正方形フォーマットでの撮影も可能です。撮影した画像もしくは端末内の画像に対して、トイカメラ風や風景写真にび##ったりなビ##ッドカラー、ソフトフォーカス、クロスプロセス、モノクロなどすぐに使える21種類のデジタルフィルターで加工することができます。さらにデジタルフィルターの他に、明るさ・コントラ##スト・彩##度など写真調整のためのパラメータ##も用意されていますので、元画像を綺麗に仕上げ##ることができます。そのほか特徴的な機能として、コミュニケーションツール「LINE」でお馴染##みのスタンプキャラクターを貼り##付けることができます。スタンプは回転拡大縮小ができるため好きな位置にピ##ット##リとレイアウトすることができます。LINEc##ame##raの特徴として、手##書きの文字やテキスト入力などの効果は、ピンチ操作による回転拡大縮小に対応しているので細##かな作り##込みをすることができます。枠・スタンプ・手##書き・テキスト入力など好みの加工が終わったら、画像を保存してブログなどに利用することができます。画像保存後には、LINEやSNSに共有できるメニューが表示されますので便利です。画面比率指定のほかに、セルフタイ##マー撮影も可能です。画像加工もアイコンをタップするだけの簡単操作。LINEでお馴染##みのユー##モ##ラスなスタンプを多数収録。手##書き文字も簡単に再レイアウトが可能となってい[SEP]

< 提案手法 2 ($\alpha=5$)

[CLS]無料で使えるデジタルフィルターや便利なスタンプ機能搭載!小##技の効##いたカメラアプリ「LINEc##ame##ra」【Androidアプリ】[SEP]画像加工編集が楽しいカメラアプリSNSやブログの更新をスマートフォンで行っている人も多くなっているようです。スマートフォンは、写真を撮って共有する方法がフィーチャーフォンより柔軟で使いやすいことや、自分の好きなカメラアプリや画像編集アプリを選##べる点も魅力の一つ。今回紹介するAndroid向けアプリ「LINEc##ame##ra」は撮##る・編集する・デコ##るなど簡単操作で個性的な写真を作って共有できるカメラアプリです。LINEc##ame##raはどんなアプリLINEc##ame##raは、カメラ機能を使って撮影もしくは端末内の画像を加工・編集できるカメラアプリです。通常の4:3の画面比率での撮影以外に、1:1の正方形フォーマットでの撮影も可能です。撮影した画像もしくは端末内の画像に対して、トイカメラ風や風景写真にび##ったりなビ##ッドカラー、ソフトフォーカス、クロスプロセス、モノクロなどすぐに使える21種類のデジタルフィルターで加工することができます。さらにデジタルフィルターの他に、明るさ・コントラ##スト・彩##度など写真調整のためのパラメータ##も用意されていますので、元画像を綺麗に仕上げ##ることができます。そのほか特徴的な機能として、コミュニケーションツール「LINE」でお馴染##みのスタンプキャラクターを貼り##付けることができます。スタンプは回転拡大縮小ができるため好きな位置にピ##ット##リとレイアウトすることができます。LINEc##ame##raの特徴として、手##書きの文字やテキスト入力などの効果は、ピンチ操作による回転拡大縮小に対応しているので細##かな作り##込みをすることができます。枠・スタンプ・手##書き・テキスト入力など好みの加工が終わったら、画像を保存してブログなどに利用することができます。画像保存後には、LINEやSNSに共有できるメニューが表示されますので便利です。画面比率指定のほかに、セルフタイ##マー撮影も可能です。画像加工もアイコンをタップするだけの簡単操作。LINEでお馴染##みのユー##モ##ラスなスタンプを多数収録。手##書き文字も簡単に再レイアウトが可能となってい[SEP]

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の展望

まとめ

- LLM API を用いて原文データから要約文を事前に生成し、要約文から得た分散表現や特徴を先行研究である CAP に組み込んだ新たなプーリング手法について提案
- テキスト分類タスクにおいて Accuracy, F1 値ともに提案手法が従来手法を上回り、その有効性を確認

今後の展望

- 要約文に対する妥当性の検討
および生成手法の改善
- 他のタスクやデータセットにおける
提案手法の有効性の検証
- 提案手法 2 におけるパラメータ α のチューニング

ご清聴ありがとうございました

ラベル推定プロンプト: (plamo-prime)

ラベル推定用プロンプト

与えられた記事の「タイトル」と「本文」に基づいて、
ふさわしい上位3つのラベルを9つのラベルから厳密に選定してください。
ラベルは 1st, 2nd, 3rd の順位で重要度順に並べ、
以下に示す JSON Schema に厳密に従って **JSON 形式** で出力してください。

ラベル一覧

- 0: 独女通信 → 独身女性向けのライフスタイル・恋愛・ファッション
- 1: IT ライフハック → IT・テクノロジー・ハウツー
- 2: 家電チャンネル → 家電・ガジェット・レビュー
- 3: livedoor HOMME → 男性向けライフスタイル・ファッション・趣味
- 4: MOVIE ENTER → 映画・エンタメ・レビュー
- 5: Peachy → 女性向けライフスタイル・美容・恋愛
- 6: エスマックス → スマホ・モバイル関連情報
- 7: Sports Watch → スポーツニュース・試合結果・選手動向
- 8: トピックニュース → 国内外の社会・時事ニュース

ラベル推定プロンプト:

JSON Schema

{schema}

出力ルール

- ・ 厳密に3つのラベルを選ぶこと
- ・ 順位は関連度の高い順
- ・ 出力形式を厳格に守ること 特に results という key を必ず持ち、子要素として 1st・2nd・3rd を持たせること
- ・ JSON 形式以外の文字は一切応答に含めないこと

記事情報

- ・ タイトル {D_{title}}
- ・ 本文: {D_{body}}


JSON 出力

出力例 : {"results":{"1st": 6, "2nd": 5, "3rd": 2}}
温度パラメータ : 0.0

實驗結果：

	評估	
	Acc	F1 值 (weighted)
Zero-Shot (Top-k, k=1)	0.3029	0.2591
Zero-Shot (Top-k, k=3)	0.4959	0.4738
Few-Shot (Top-k, k=1)	0.3355	0.2885
Few-Shot (Top-k, k=3)	0.5964	0.6106

実験結果：混合行列（提案手法）



実験結果：実験時間 (colab T4)

- 従来手法: 70 分
- 提案手法: 100 分

提案手法でのみ正解したデータ例

<原文>

【二股女を演じたリース・ウィザースプーンって何者なのか】

ハリウッドでは有名であるが、日本だと映画好きでないとわからない。そんなスターがたくさんいるだろう。映画『Black & White / ブラック & ホワイト』に出演しているリース・ウィザースプーンも、もしかするとその一人なのかも知れない。映画の中では、二人のCIAのスパイから言い寄られて、思わず二股をかけてしまうモテモテ女性のローレン役を演じている。そんな彼女は一体、どんな女優なのだろうか。

日本で一番、わかりやすく彼女を言うなら「『キューティ・ブロンド』の主人公エルの人」だろうか。(中略)。実はすごい女優なのである。

その他にも、「高額ギャラ番付」でトップに選ばれたり、国連女性開発基金の親善大使として活動したりと話題に事欠かない。アメリカ独立宣言に署名したジョン・ウィザースプーンの子孫の一人というおまけもある。

こうなるとウィザースプーンに興味をわいてこないだろうか。映画『Black & White / ブラック & ホワイト』で、どんな演技をしたのか気になるところである。

512 トークン

そんなウィザースプーンは今回の役であるローレンの二面性を気に入っているようだ。「仕事では、ローレンはすぐれた決断力を見せますが、プライベートでは、優柔不断です。彼女が、“わたしは自分にぴったりの人を選んでるか”と悩む気持ちには多くの人が共感できると思います」とコメントしている。

現在、ムービーエンターではこの映画の特別試写会の参加者を募集をしている。

・映画『Black&White/ブラック&ホワイト』特別試写会(締切:2012年3月26日)

この映画の試写会だが、様々なサイトで「女性限定」で参加者を募集していた。

しかし今回の募集は「男性」も応募できる。必要条件は、感想をツイッターでつぶやいてくれることだけ。リース・ウィザースプーンの魅力を堪能したい人はぜひともこの機会に応募してみよう。

・MOVIE ENTER(ムービーエンター) (以下略)

<要約文>

本文では、映画「Black & White/ブラック & ホワイト」で、2人の男性の間に揺れ動く女性を演じた女優のリース・ウィザースプーンについて触れています。彼女は「キューティ・ブロンド」の主人公であるエルの役で日本でも有名ですが、ハリウッドではそれ以前から注目されていた女優です。

リース・ウィザースプーンは、これまでに数多くの賞を受賞しており、演技力の高さが評価されています。映画「Walk the Line/君につづく道」では、アカデミー賞主演女優賞などを受賞しました。また、彼女は国連女性開発基金の親善大使としても活動しています。

「Black & White/ブラック & ホワイト」では、彼女が演じるローレンの二面性が見どころであり、リース・ウィザースプーン自身もこの役を楽しんで演じたとコメントしています。


現在、この映画の特別試写会の参加者が募集されており、性別を問わず応募が可能です。試写会では、リース・ウィザースプーンの魅力を堪能することができるでしょう。

正解ラベル: MOVIE ENTER


従来手法での推定結果: Peachy

実験結果：学習曲線 (Train Loss / Validation Loss)

① 提案手法



② 従来手法 (CAP)



③ E_{sum} のみ

