

BERT を用いた原文と要約文の 分散表現の最適な統合手法の検討

創発ソフトウェア研究室

M2 高山 裕成

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の課題

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の課題

大規模言語モデル (Large Language Models, LLM) の進化

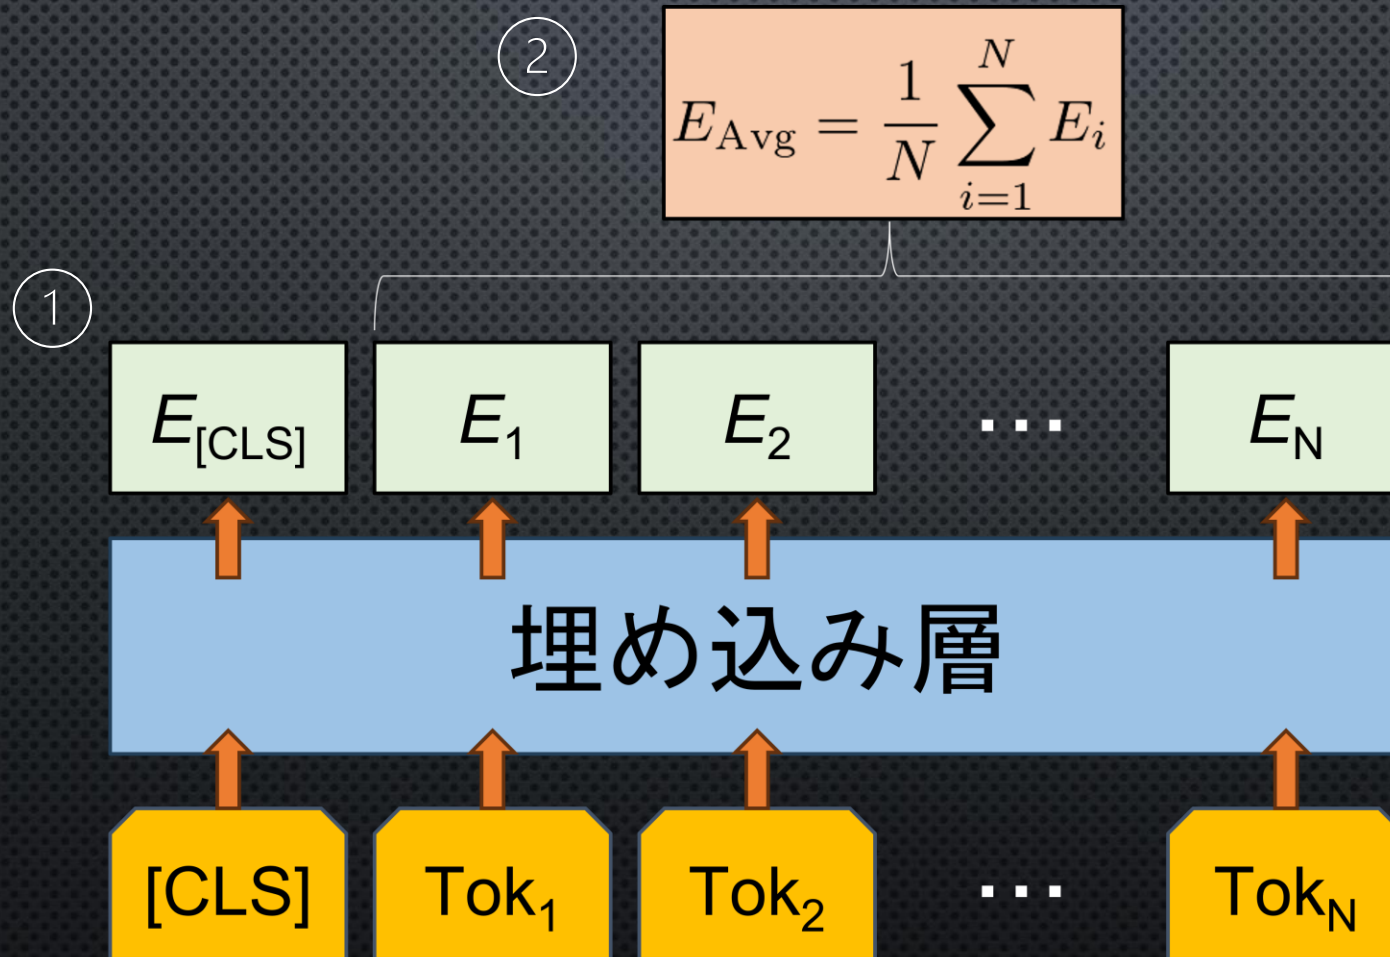
Transformer 構造を持つ BERT や
GPT (Generative Pre-trained Transformer) など
LLM の利用需要が拡大

- ・ チャット bot
- ・ コンテンツ生成
- ・ ビッグデータ分析
など



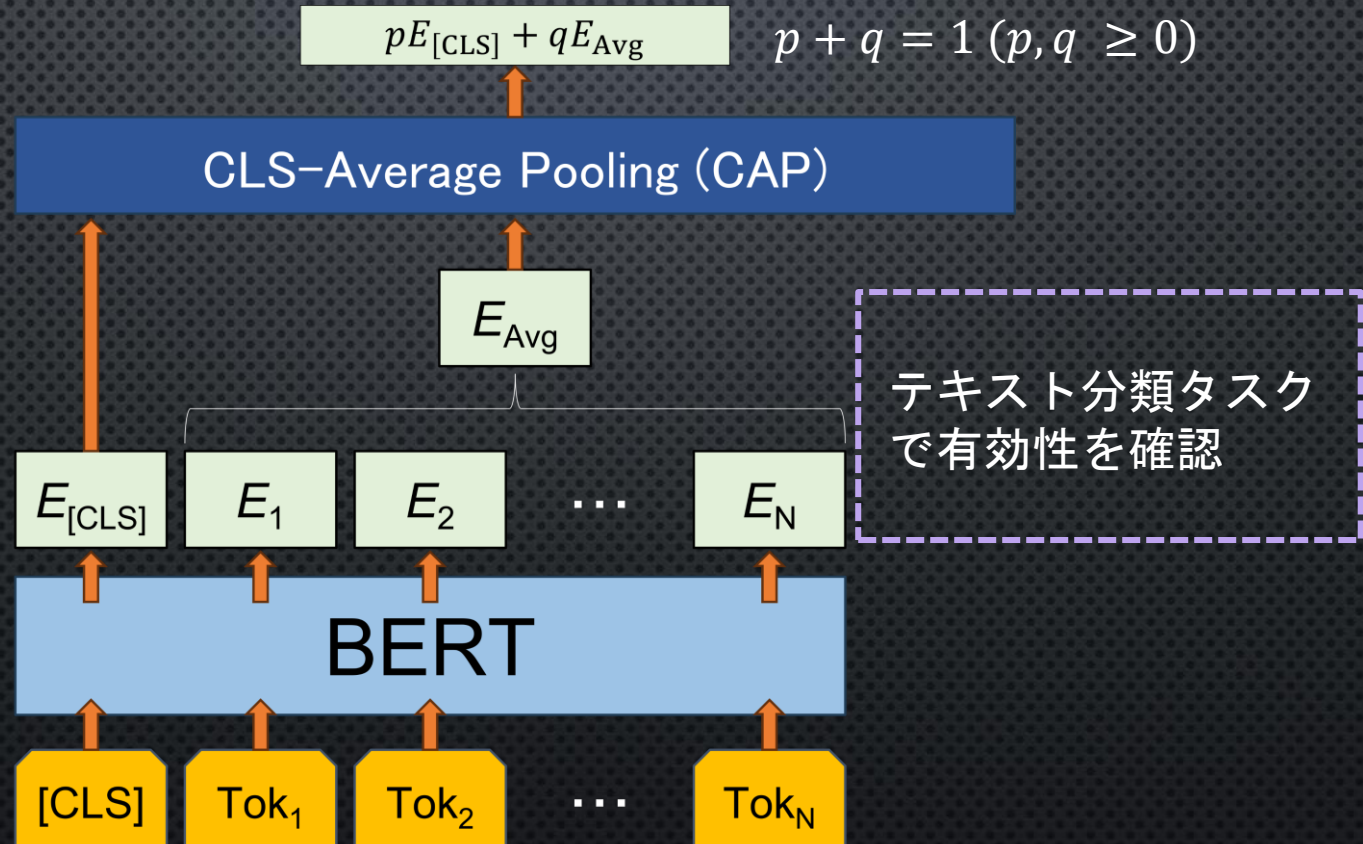
⇒ より高性能なモデルの構築のためには
文章全体の適切な分散表現を獲得し
最適な処理の選択が重要

自然言語処理における分散表現のプーリング例



先行研究

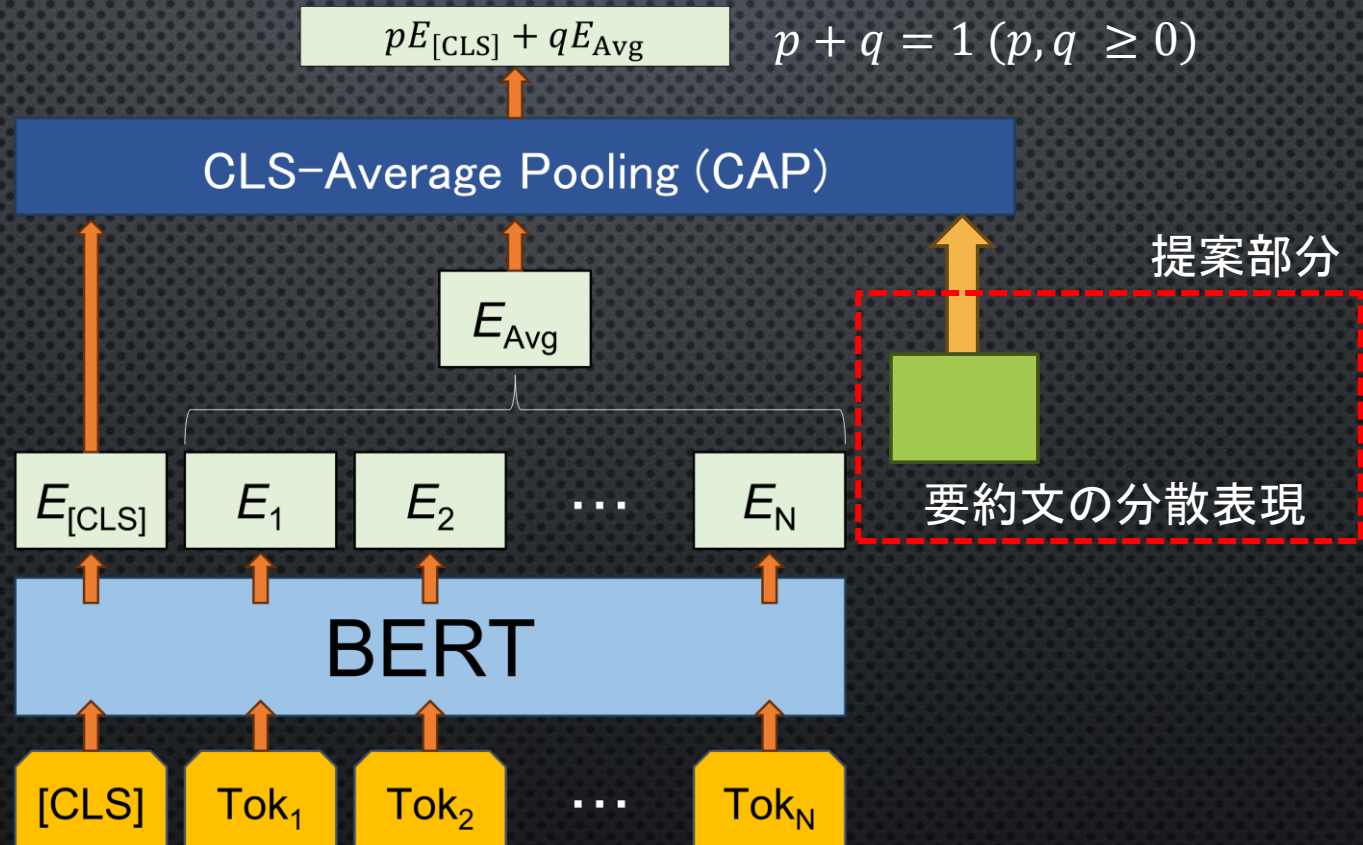
CLS-Average Pooling (CAP) 層の導入 [大和, 2024]



大和秀徳. BERT の分散表現に対する学習可能な重みを持つプーリング手法の提案, 大阪公立大学大学院情報学研究科 基幹情報学専攻 知能情報分野 修士論文, 2024

先行研究

CLS-Average Pooling (CAP) 層の導入 [大和, 2024]



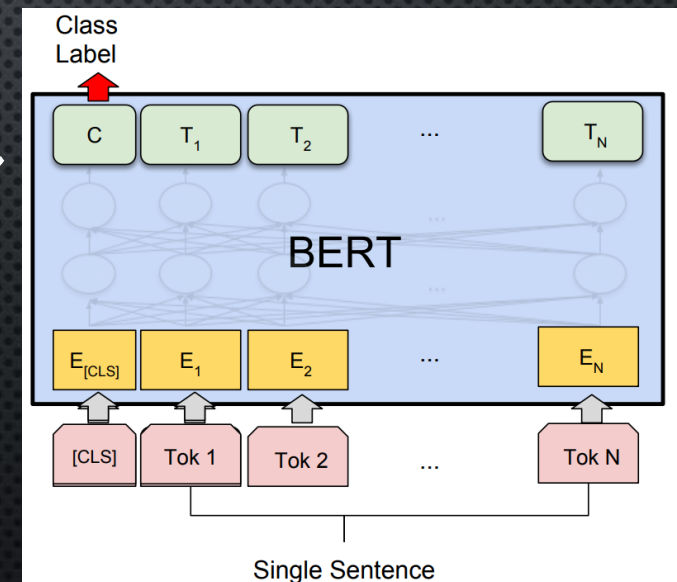
大和秀徳. BERT の分散表現に対する学習可能な重みを持つプーリング手法の提案, 大阪公立大学大学院情報学研究科 基幹情報学専攻 知能情報分野 修士論文, 2024

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の課題

BERT^[1] (Bidirectional Encoder Representations from Transformers)

- 複数の双方向 Transformer に基づく汎用言語モデル
- 事前学習済みモデルを他のタスクに転移させることが容易
- 東北大学による事前学習モデル BERT-base^[2] を使用



[1]Devlin, Jacob and Chang, Ming-Wei and Lee, Kenton and Toutanova, Kristina.
BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. 2019.

[2]<https://huggingface.co/cl-tohoku/bert-base-japanese-v3>

PLaMo

- Preferred Elements 社が開発・公開している日本語に特化した大規模言語モデル
- 既存モデルをベースに用いず合計 2 兆トークン分のテキストデータで事前学習 (PLaMo-100B モデル)
- PLaMo-100B モデルをベースに指示学習やモデルマージを行うことで強化されたモデルを API で利用可

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の課題

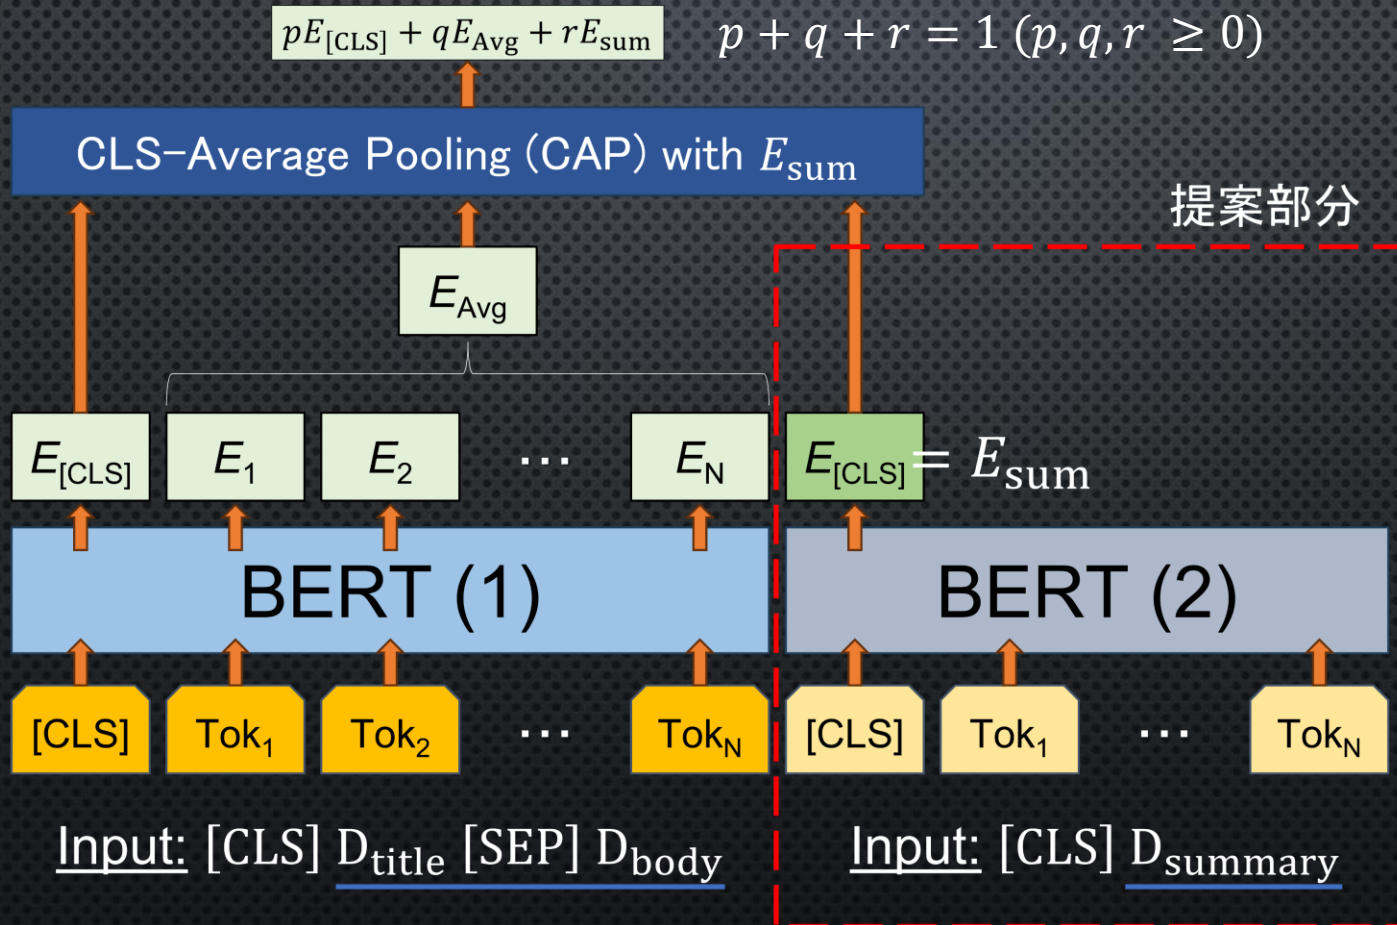
データセット

livedoor ニュースコーパスデータセット

- livedoor ニュースの記事を収集, HTML タグを除去
- 9つのカテゴリ, 計 7,367 記事
- 各記事データ D はカテゴリ名 D_{label} , 記事タイトル D_{title} , 記事本文 D_{body} などのメタデータから構成
- 本研究では以下のようにラベルとカテゴリ名を対応
 - 0 : 独女通信
 - 1 : IT ライフハック
 - 2 : 家電チャンネル
 - 3 : livedoor HOMME
 - 4 : MOVIE ENTER
 - 5 : Peachy
 - 6 : エスマックス
 - 7 : Sports Watch
 - 8 : トピックニュース

提案手法

CAP 層における要約文ベクトル項 E_{sum} の追加



提案手法

学習可能パラメータ p, q, r の更新式

更新後のパラメータを p', q', r' とすると

$$p' = \frac{p^2}{p^2 + q^2 + r^2}, q' = \frac{q^2}{p^2 + q^2 + r^2}, r' = \frac{r^2}{p^2 + q^2 + r^2}$$

要約文 D_{summary} の生成手法 (PLaMo API を使用)

1. 各記事データ D に含まれる, D_{title} および D_{body} から
プロンプトを作成
2. PLaMo API からの回答を要約文 D_{summary} とする

$$\left\{ \begin{array}{l} D_{\text{summary}} = \mathcal{L}(D_{\text{prompt}}) \quad \mathcal{L} : \text{大規模言語モデル API (e.g., ChatGPT API, PLaMo API)} \\ D_{\text{prompt}} = \left[\begin{array}{l} \text{"role" : "system", "content" : "あなたは優秀な AI アシスタントです。"} \\ \text{"role" : "user", "content" : "以下は「 D_{title} 」というタイトルの"} \\ \text{記事の本文です。内容を要約し、} \\ \text{結果のみを出力してください。"} \\ \text{"role" : "user", "content" : " D_{body} "} \end{array} \right] \end{array} \right.$$

要約文の生成例 1 (ラベル: 独女通信)

<原文>

【健康のために体張ります! Presented by ゆるっとcafé】

みなさま、こんにちは!
私は以前、「アラフォーだけど結婚したい!」という
コラムを書かせていただいた漫画家の尾形未紀です。
40代半ばで結婚した私たち夫婦。子供はできるかどうかまだわからないし、親ももうかなりいい年だから、あまり頼ることもできない!
だから夫婦2人でしっかり支えあって生きていかなくてはいけないと思う今日この頃…。でも、そんなときに気になるのが「健康」。
長生きしても健康じゃなきゃ、楽しくないもんね?
独女のみなさんも、年々老いてくるにしたがって、増えてくる悩みに頭を抱えてるのでは!? 疲れがとれにくくなったり、シミやしわが増えてきたり、二日酔いがなかなか治らなかったり…
さらに、病気で入院したりする友達や知り合いも増えているのでは? 体にいろいろと不具合が出始めてる頃ではないでしょうか…!?
私の担当編集のアラサー女子も、
「最近、髪が薄くなってきた…」と嘆いてます(笑)。
健康に関する悩みって、周りからは「気にしすぎ」と思うことでも、本人にとっては真剣なものね。
そこで、みなさんの身近な健康や美容に関する悩みを私たち夫婦が解決していく「健康コミックエッセイ」をはじめることになりました!
少しでも健康でいて、長生きを!
それを目標にがんばりたいと思いますので、
独女のみなさんもぜひ読んでみてくださいね♪

<要約文>

この文章では、尾形未紀の新シリーズ「健康コミックエッセイ」の紹介がされています。

このエッセイでは、健康や美容に関する身近な悩みについて取り上げ、解決策を探っていきます。
尾形未紀と夫の夫婦二人三脚で、充実した健康的な生活を送るためのサポートを読者に提供する目的があるようです。具体的には、疲れやすさ、老化による見た目の変化、アルコールの影響、病気や入院に関する不安、髪の健康など、幅広いトピックが取り上げられる予定です。このエッセイは、主に独女(独身女性)の健康や美容に関する悩みに焦点を当てていますが、健康に関心のある読者にとって有益な情報を提供することを目指しています。

要約文の生成例 2 (ラベル: MOVIE ENTER)

<原文>

【C-3POが名場面を紹介する『スター・ウォーズinコンサート』日本上陸】

2009年4月にロンドンにて世界初初演し、同年より2010年にかけて北米、欧州ツアーを行い、175万人以上を動員した『スター・ウォーズinコンサート』の、日本公演が遂にアジア初として決定した。通常は、1万5千人規模のアリーナ級の会場で行われていたが、今回は演出と音響の質を最大限に引き出すため、約4500人規模のホール級会場での公演が実現。更なる臨場感と興奮が味わえるショーとなり、目と耳の肥えた日本のファンに向けたプレミアムなコンサートとなる。

『スター・ウォーズinコンサート』は特別に編集された映画の名場面を、巨大LEDスクリーンに映し、ジョン・ウィリアムズのスリリングな楽曲の演奏にライブでシンクロする。また、全6作でC-3PO役を演じたアンソニー・ダニエルズが、名場面のナレーションを行うことにより、スター・ウォーズに新しい生命を吹き込み、観客を興奮の世界と誘う。

東京公演は、8月9日から8月12日に東京国際フォーラム ホールAで、大阪公演は、8月15日にグランキューブ大阪で行われる。詳細は、公式サイトで確認できる。

ジョージ・ルーカスが全精力を傾注し、最新テクノロジーを駆使した3D映画として、再び大スクリーンに帰ってくことで注目される『STAR WARS エピソード1/ファントム・メナス 3D』の公開も3月16日と迫っている。今年は「スター・ウォーズ」の熱が全世界を包むことだろう。

【スター・ウォーズ関連記事】

・ダース・ベイダーにより守り神ビリケンさんが ... (略)

<要約文>

『スター・ウォーズinコンサート』アジア初の日本公演が東京と大阪で開催されます。このコンサートは、映画の名場面を巨大LEDスクリーンで映し、ジョン・ウィリアムズの楽曲の演奏に合わせて楽しむものです。特別ゲストとして、全6作でC-3POを演じたアンソニー・ダニエルズが名場面のナレーションを行います。東京公演は8月9日から12日まで東京国際フォーラム ホールA、大阪公演は8月15日にグランキューブ大阪で行われます。ジョージ・ルーカスが監督した『スター・ウォーズ エピソード1/ファントム・メナス 3D』の公開も3月16日に予定されており、今年はスター・ウォーズの熱が世界中を包み込むでしょう。

発表の流れ

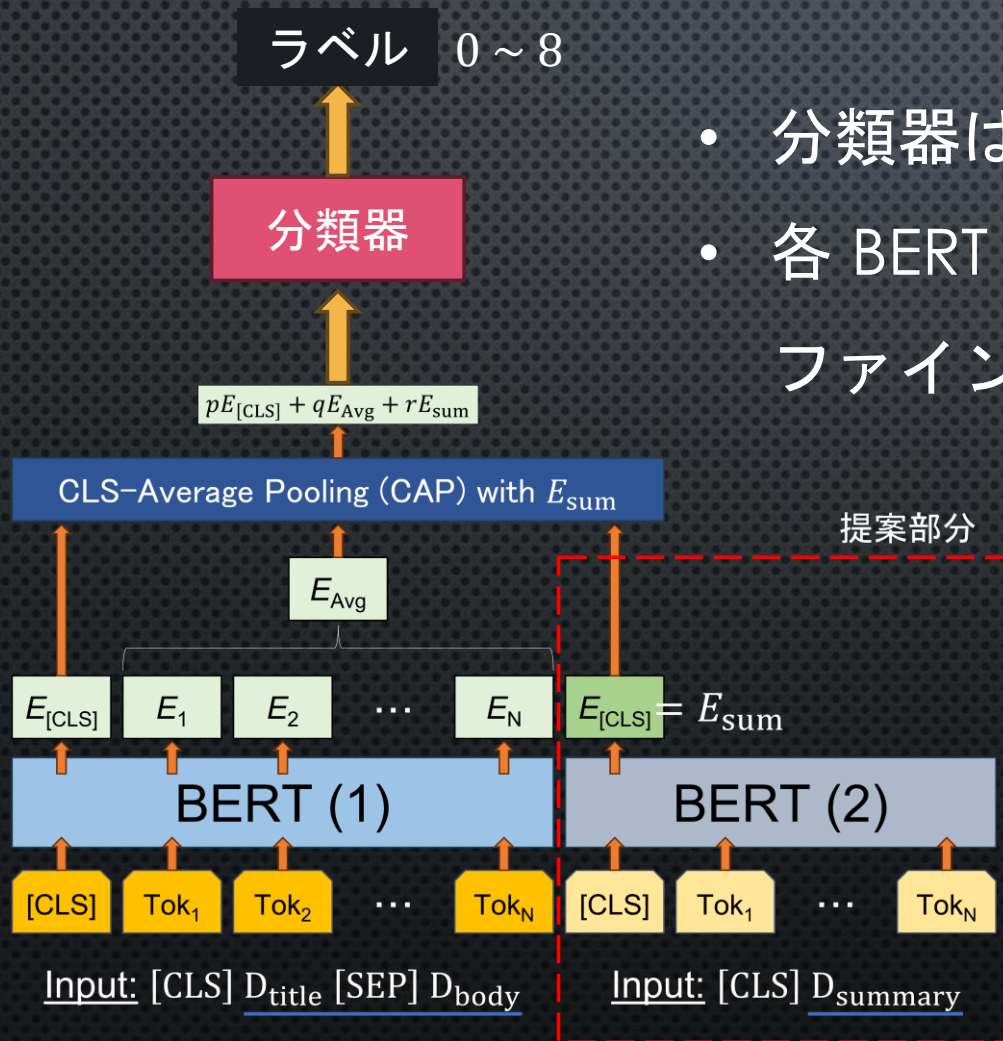
- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の課題

実験設定

- livedoor ニュースコーパスデータセットを用いた
テキスト分類 (記事ラベル推定)
- 訓練データ : 検証データ : テストデータ = 8 : 1 : 1 に分割
- 検証データにおける F1 値 が最も高い epoch における
モデルで評価する

label	0	1	2	3	4	5	6	7	8	合計
訓練	684	695	690	421	700	645	713	716	631	5,895
検証	88	80	88	42	93	100	77	105	63	736
テスト	98	95	86	48	77	97	80	79	76	736

実験設定



- 分類器は 1 層の全結合層
- 各 BERT モデルは最終層のみをファインチューニング

実験パラメータ

学習パラメータ	値
エポック数	20
バッチサイズ	16
最適化手法	Adam
学習率	3.0×10^{-5}
損失関数	Cross Entropy Loss
分類器	全結合層


	重み初期値
従来手法	$(p, q) = (\frac{1}{2}, \frac{1}{2})$
提案手法	$(p, q, r) = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$

実験結果：精度評価


	評価	
	Acc	F1 値 (weighted)
① 提案手法 (CAP with E_{sum})	0.9687	0.9683
② 従来手法 (CAP)	0.9565	0.9560
③ E_{sum} のみ	0.8369	0.8340
ベースライン	0.1111	-

実験結果：学習曲線 (Train Loss / Validation Loss)


① 提案手法



② 従来手法 (CAP)

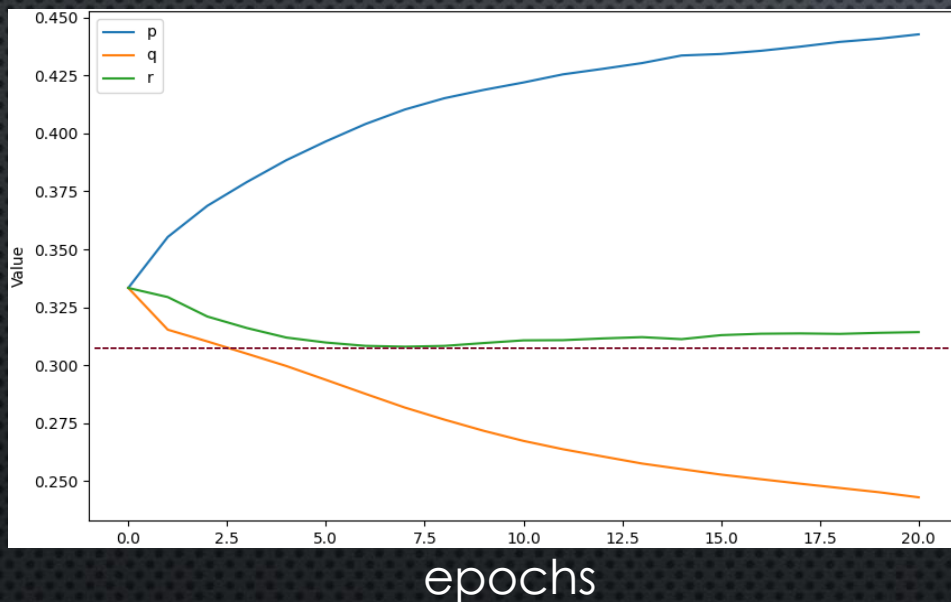


③ E_{sum} のみ




実験結果：学習曲線

① 提案手法 (パラメータ p , q , r の推移)



② 従来手法 (パラメータ p , q の推移)



学習後のパラメータの値:


$$(p, q, r) = (0.441, 0.245, 0.314)$$

$$(p, q) = (0.613, 0.387)$$

実験結果：トークン数による学習への影響

訓練用データのトークン数分布

	トークン数	
	< 512	≥ 512
原文	2148	3747
要約文	5884	11



- =>
- ・ 欠損した原文データの重要な文脈情報の補完
 - ・ 原文データの重要な文脈情報の強調

提案手法でのみ正解したデータ例

<原文>

【二股女を演じたリース・ウィザースプーンって何者なのか】

ハリウッドでは有名であるが、日本だと映画好きでないとわからない。そんなスターがたくさんいるだろう。映画『Black & White / ブラック & ホワイト』に出演しているリース・ウィザースプーンも、もしかするとその一人なのかも知れない。映画の中では、二人のCIAのスパイから言い寄られて、思わず二股をかけてしまうモテモテ女性のローレン役を演じている。そんな彼女は一体、どんな女優なのだろうか。

日本で一番、わかりやすく彼女を言うなら「『キューティ・ブロンド』の主人公エルの人」だろうか。(中略)。実はすごい女優なのである。

その他にも、「高額ギャラ番付」でトップに選ばれたり、国連女性開発基金の親善大使として活動したりと話題に事欠かない。アメリカ独立宣言に署名したジョン・ウィザースプーンの子孫の一人というおまけもある。

こうなるとウィザースプーンに興味をわいてこないだろうか。映画『Black & White / ブラック & ホワイト』で、どんな演技をしたのか気になるところである。

512 トークン

そんなウィザースプーンは今回の役であるローレンの2面性を気に入っているようだ。「仕事では、ローレンはすぐれた決断力を見せますが、プライベートでは、優柔不断です。彼女が、“わたしは自分にぴったりの人を選んでるか”と悩む気持ちには多くの人が共感できると思います」とコメントしている。

現在、ムービーエンターではこの映画の特別試写会の参加者を募集をしている。

・映画『Black&White/ブラック&ホワイト』特別試写会(締切:2012年3月26日)

この映画の試写会だが、様々なサイトで「女性限定」で参加者を募集していた。

しかし今回の募集は「男性」も応募できる。必要条件は、感想をツイッターでつぶやいてくれることだけ。リース・ウィザースプーンの魅力を堪能したい人はぜひともこの機会に応募してみよう。

・MOVIE ENTER(ムービーエンター) (以下略)

<要約文>

本文では、映画「Black & White/ブラック & ホワイト」で、2人の男性の間に揺れ動く女性を演じた女優のリース・ウィザースプーンについて触れています。彼女は「キューティ・ブロンド」の主人公であるエルの役で日本でも有名ですが、ハリウッドではそれ以前から注目されていた女優です。

リース・ウィザースプーンは、これまでに数多くの賞を受賞しており、演技力の高さが評価されています。映画「Walk the Line/君につづく道」では、アカデミー賞主演女優賞などを受賞しました。また、彼女は国連女性開発基金の親善大使としても活動しています。

「Black & White/ブラック & ホワイト」では、彼女が演じるローレンの二面性が見どころであり、リース・ウィザースプーン自身もこの役を楽しんで演じたとコメントしています。

現在、この映画の特別試写会の参加者が募集されており、性別を問わず応募が可能です。試写会では、リース・ウィザースプーンの魅力を堪能することができるでしょう。

正解ラベル: MOVIE ENTER

従来手法での推定結果: Peachy

発表の流れ

- はじめに
- 要素技術
- 提案手法
- 数値実験
- まとめと今後の課題

まとめ


- LLM を用いて原文データから要約文を事前に生成し、要約文から得た分散表現を先行研究である CAP 層に組み込んだ新たなプーリング手法について提案
- テキスト分類タスクにおいて Accuracy, F1 値ともに提案手法が従来手法を上回り、その有効性を確認

今後の課題

- 要約文に対する妥当性の検討
および生成手法の改善
- 他のタスクやデータセットにおける
提案手法の有効性の検証
- 長い入力系列を扱うことができる汎用的かつ低コストな
プーリング手法の模索

ご清聴ありがとうございました

実験結果：混合行列（提案手法）



実験結果：実験時間 (colab T4)

- 従来手法: 70 分
- 提案手法: 90 分